TRƯỜNG ĐẠI HỌC PHENIKAA

BÀI TẬP LỚN MÔN HỌC MÁY

PHÁT HIỆN GIAN LẬN GIAO DỊCH THẺ TÍN DỤNG BẰNG MACHINE LEARNING

Credit Card Fraud Detection

Giảng viên hướng dẫn: Nguyễn Ngọc Giang

NHÓM 6

Trương Việt Thành MSV 24106898
Bùi Khánh Linh MSV 24100543
Nguyễn Kinh Bang MSV 24101477

Đặt vấn đề

Thanh toán thẻ tạo ra lượng giao dịch lớn.

Gian lận gây rủi ro tài chính cho chủ thẻ và đơn vị xử lý.

Kiểm tra thủ công từng giao dịch khó đáp ứng quy mô này.

Mô hình hỗ trợ ưu tiên các giao dịch cần kiểm tra.



Mục tiêu và quy trình thực hiện

Phân tích dữ liệu giao dịch và xây dựng bộ phân loại hai lớp.
So sánh ba thuật toán trên cùng validation, sau đó đánh giá test độc lập.
Hoàn thiện ứng dụng Streamlit để demo dự đoán theo lô CSV.



Dữ liệu gốc giữ nguyên. Mỗi giai đoạn có notebook và kết quả lưu riêng.

Bộ dữ liệu Credit Card Fraud Detection

284.807
giao dịch ban đầu

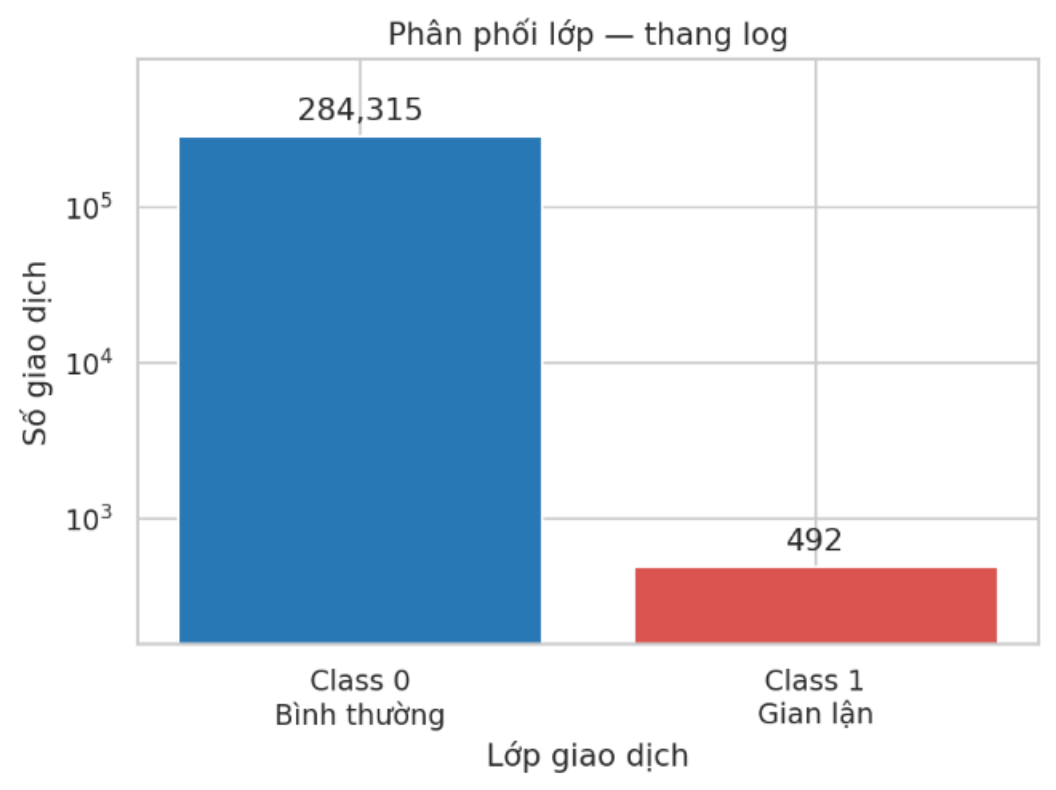
284.315 bình thường
492 gian lận

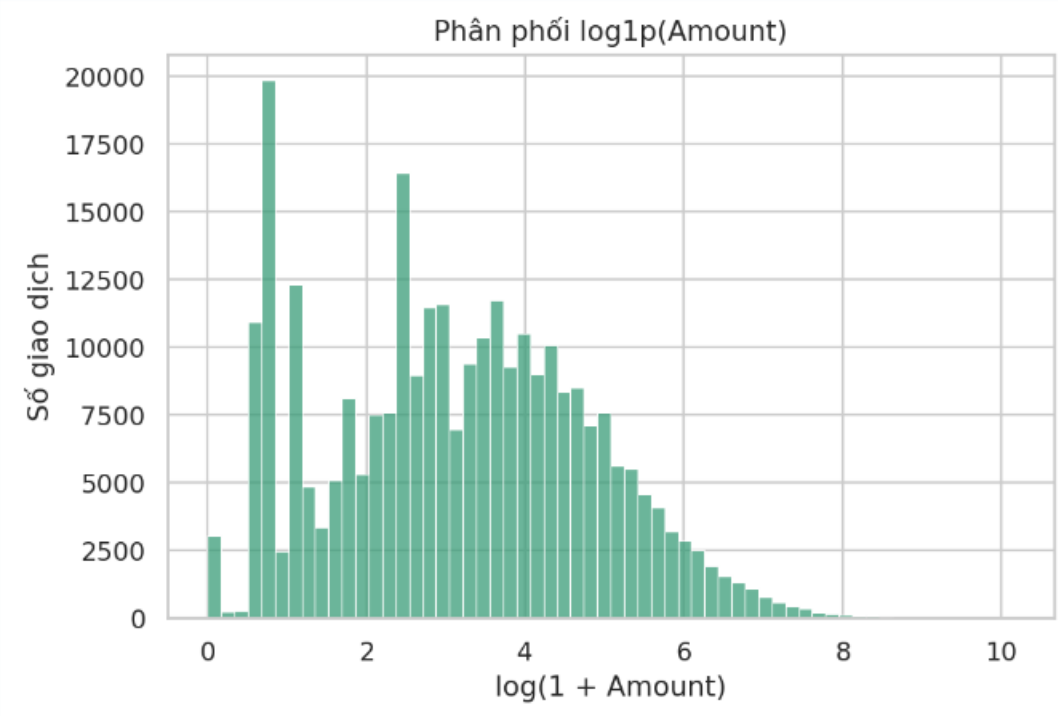
0,1727%
tỷ lệ giao dịch gian lận

Cột	Ý nghĩa
Time	Số giây từ giao dịch đầu
Amount	Số tiền giao dịch
V1–V28	28 đặc trưng qua PCA
Class	0: bình thường, 1: gian lận

30 đặc trưng đầu vào và 1 cột nhãn.
Các đặc trưng PCA đã ẩn danh thông tin gốc.

EDA: mất cân bằng và phân phối Amount





Khoảng 578 giao dịch bình thường cho mỗi giao dịch gian lận.

Amount lệch phải mạnh.
Trung vị 22,00; trung bình 88,35.

Tiền xử lý và kiểm soát rò rỉ dữ liệu



stratify=y và random_state=42; không có đặc trưng trùng giữa hai tập.

Time/Amount: scaler chỉ fit trên train. Khi tách validation, LR dùng Pipeline mới.
Random Forest và XGBoost dùng dữ liệu thô, giữ nguyên V1–V28.

Ba thuật toán Machine Learning

Logistic Regression

Ước lượng xác suất bằng mô hình tuyến tính.

Đơn giản, dễ diễn giải và làm mốc so sánh ban đầu.

class_weight="balanced"
Pipeline scale Time/Amount

Random Forest

Nhiều cây quyết định cùng tham gia dự đoán.

Nắm bắt quan hệ phi tuyến, ít phụ thuộc chuẩn hóa.

100 cây
class_weight="balanced"

XGBoost

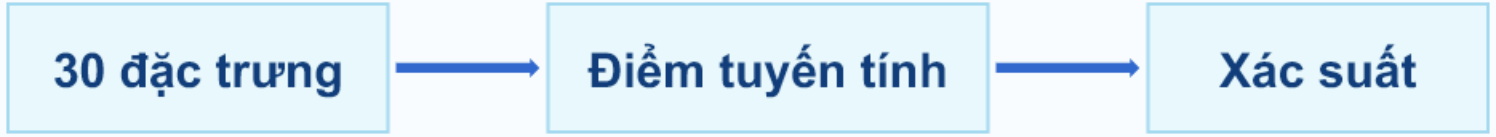
Bổ sung cây tuần tự để giảm hàm mất mát.

Mô hình boosting mạnh cho dữ liệu dạng bảng.

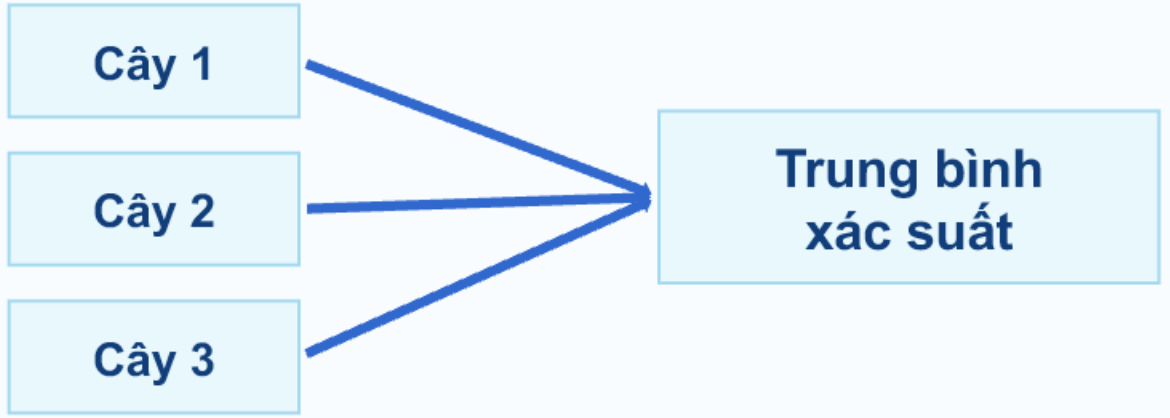
200 cây, learning_rate=0,05
scale_pos_weight từ training

Nguyên lý và cách tiếp cận

Logistic Regression



Random Forest



XGBoost



Thêm cây theo hướng giảm lỗi

Quá trình huấn luyện

Từ 226.980 dòng train, tách validation 20% cố định bằng stratify và seed 42.

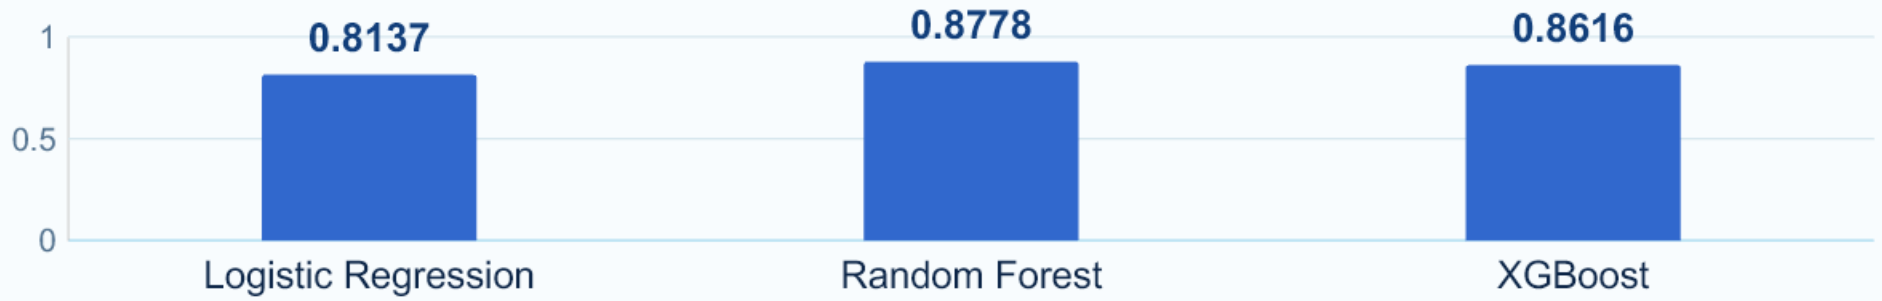
Tập	Số giao dịch	Ca gian lận
Training subset	181.584	302
Validation	45.396	76

Mô hình	Các cấu hình đã thử
Logistic Regression	C = 1 và 0,1; class_weight balanced
Random Forest	100 cây; min_samples_leaf = 1 và 2
XGBoost	200 cây; max_depth = 4 và 3; learning_rate = 0,05

6 cấu hình, cùng validation. AP là tiêu chí chính; xem thêm F1, Precision và Recall.

So sánh kết quả trên validation

Mô hình	Precision	Recall	F1	AP
Logistic Regression	0,0544	0,8947	0,1025	0,8137
Random Forest	**0,9545**	**0,8289**	**0,8873**	**0,8778**
XGBoost	0,4820	0,8816	0,6233	0,8616



Cấu hình tốt nhất của mỗi thuật toán, ngưỡng 0,50. Random Forest có AP cao nhất.

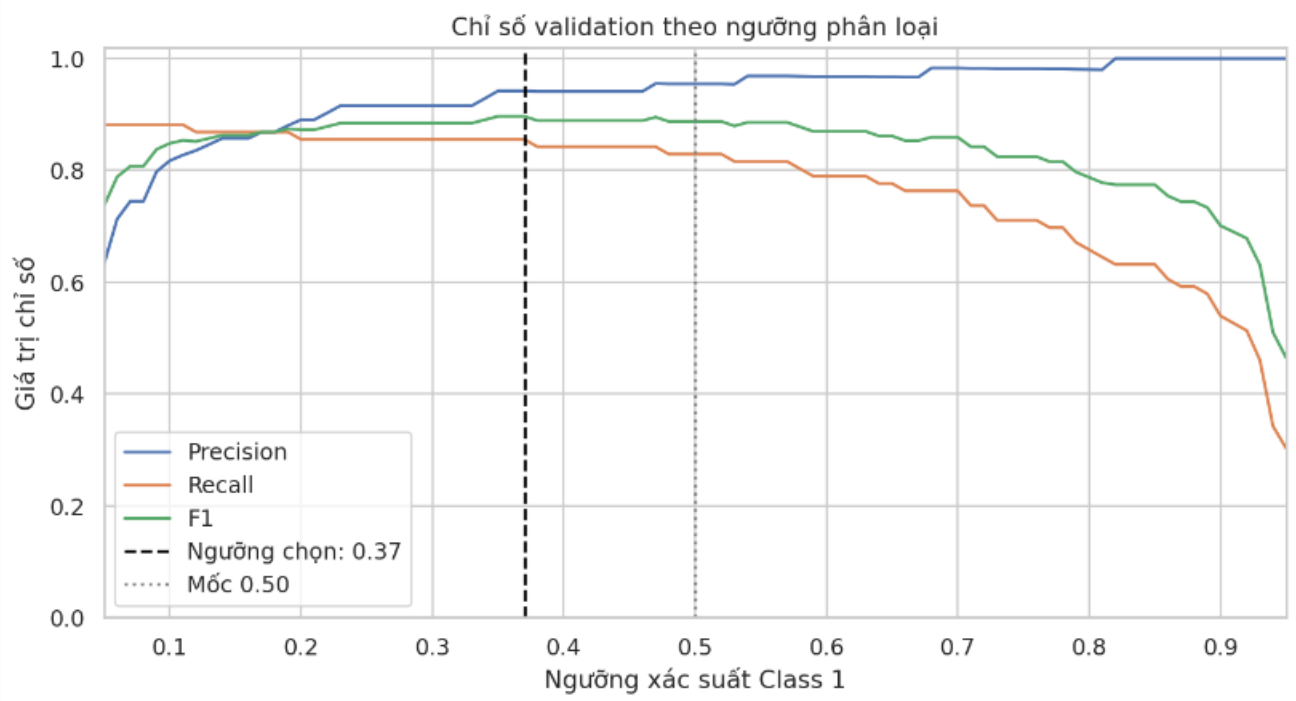
Lựa chọn Random Forest và ngưỡng

rf_leaf2

AP validation: 0,8778
F1 tại ngưỡng 0,50: 0,8873

100 cây, min_samples_leaf = 2
class_weight = balanced
max_depth = None, seed = 42

Ngưỡng chọn: 0,37
F1 validation: 0,8966



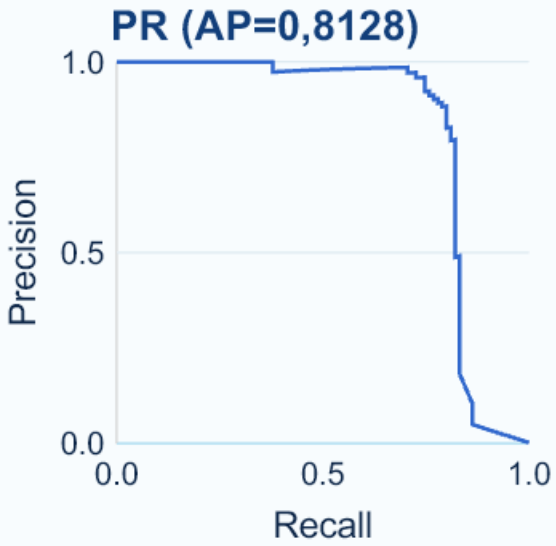
Ngưỡng chốt trên validation trước khi đọc test.
Accuracy cao vẫn có thể bỏ sót gian lận.

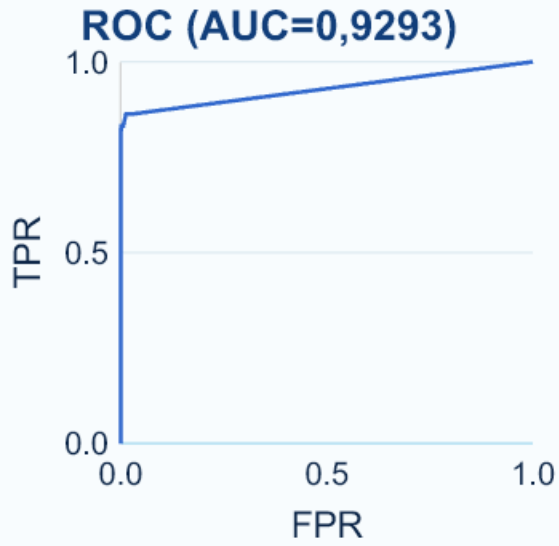
Đánh giá cuối cùng trên tập test

Precision	Recall	F1-score	Average Precision
0,9589	**0,7368**	**0,8333**	**0,8128**

Confusion Matrix

Thực tế / Dự đoán	Bình thường	Gian lận
Bình thường	56648	3
Gian lận	25	70





70/95 ca gian lận phát hiện đúng; bỏ sót 25 ca; cảnh báo nhầm 3 giao dịch.

Test: 56.746 giao dịch. Ngưỡng 0,37 cố định từ validation. Mô hình đã refit toàn bộ train.

Ứng dụng demo Streamlit



Tải CSV

Kiểm tra đủ 30 đặc trưng số,
sắp đúng thứ tự từ features.json.

Dự đoán và xem kết quả

Model đã lưu, ngưỡng từ JSON.
Thống kê, lọc, sắp xếp và đánh giá nhãn.

Xuất CSV

Giữ dữ liệu gốc, thêm fraud_score
và prediction. Không huấn luyện lại.

Ảnh demo: 20 giao dịch thật được chọn để minh họa, không đại diện tỷ lệ gian lận.

Hạn chế và hướng phát triển

Hạn chế hiện tại

1. Chỉ 473 ca gian lận sau bỏ trùng.

2. Test vẫn bỏ sót 25/95 ca gian lận.

3. PCA làm giảm khả năng giải thích trực tiếp theo nghiệp vụ.

4. Một dataset và một phân hoạch chưa bảo đảm hiệu quả triển khai.

Hướng phát triển

1. Thử xử lý mất cân bằng đúng trong training/fold.

2. Chọn ngưỡng theo chi phí bỏ sót và cảnh báo nhầm.

3. Bổ sung cách giải thích mô hình cho người kiểm tra giao dịch.

4. Đánh giá dữ liệu mới, theo dõi thay đổi phân phối, cải thiện demo.

Kết luận

01. Hoàn thành EDA và tiền xử lý, giữ nguyên dataset gốc.

02. Huấn luyện và so sánh Logistic Regression, Random Forest, XGBoost.

03. Chọn Random Forest bằng validation, chốt ngưỡng 0,37.

04. Đánh giá test độc lập và hoàn thiện demo Streamlit.

Hệ thống hỗ trợ ưu tiên kiểm tra các giao dịch đáng nghi ngờ.

Cảm ơn thầy/cô và các bạn đã lắng nghe!